KNN_credit_risk_answer

August 4, 2023

1 Bài toán Dự đoán tín dụng cá nhân:

- Đưa vào một số thông tin của người dùng, dự đoán xem người đó có tín dụng tốt hay là xấu
- Thực hành sử dụng mô hình K-Nearest Neighbors (KNN) để giải quyết bài toán này # Nội dung thực hành:
- Trực quan hóa dữ liệu (Data visualization)
- Tiền xử lý dữ liệu
- Huấn luyện và đánh giá mô hình KNN
- Lựa chọn siêu tham số và các thuộc tính đầu vào cho mô hình

2 *Import libraries*

[1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
seed = 42
```

3 *Load Bank Personal Loan Modelling dataset & explore*

- Dữ liệu được lấy từ Statlog (German Credit Data) Data Set https://archive.ics.uci.edu/ml/datasets/Statlog+%28German+Credit+Data%29
- mỗi người được biểu diễn bằng 24 thuộc tính
- Nhãn 1: là người đó có tín dụng tốt
- Nhãn 0: là người đó có tín dụng xấu
- Ma trận chi phí (cost matrix): Chi phí khi đánh giá sai tín dụng xấu thành tốt (5) cao hơn khi đánh giá sai tín dụng tốt thành xấu (1)

[2]:
```
cost_matrix = np.array([[0, 5], [1, 0]])
print('Nếu tín dụng xấu được phân là xấu, chi phí:', cost_matrix[0][0])
print('Nếu tín dụng xấu được phân là tốt, chi phí:', cost_matrix[0][1])
print('Nếu tín dụng tốt được phân là xấu, chi phí:', cost_matrix[1][0])
print('Nếu tín dụng tốt được phân là tốt, chi phí:', cost_matrix[1][1])
```

```
Nếu tín dụng xấu được phân là xấu, chi phí: 0
Nếu tín dụng xấu được phân là tốt, chi phí: 5
```

Nếu tín dụng tốt được phân là xấu, chi phí: 1
Nếu tín dụng tốt được phân là tốt, chi phí: 0

[4]:
```
data_array = np.genfromtxt('german.data-numeric')
data_frame = df = pd.DataFrame(data_array, columns=['A'+str(i) for i in␣
 ↪range(1, 25)]+['label'])
# ban đầu nhãn là 1: good, 2: bad
# để đơn giản ta chuyển về 1: good, 0: bad
data_frame['label'] = data_frame['label'].replace(2, 0)
data_frame
```

[4]:

	A1	A2	A3	A4	A5	A6	A7	A8	A9	A10	…	A16	A17	A18	\
0	1.0	6.0	4.0	12.0	5.0	5.0	3.0	4.0	1.0	67.0	…	0.0	0.0	1.0	
1	2.0	48.0	2.0	60.0	1.0	3.0	2.0	2.0	1.0	22.0	…	0.0	0.0	1.0	
2	4.0	12.0	4.0	21.0	1.0	4.0	3.0	3.0	1.0	49.0	…	0.0	0.0	1.0	
3	1.0	42.0	2.0	79.0	1.0	4.0	3.0	4.0	2.0	45.0	…	0.0	0.0	0.0	
4	1.0	24.0	3.0	49.0	1.0	3.0	3.0	4.0	4.0	53.0	…	1.0	0.0	1.0	
..	…	…	…	…	…	…	…	…	…	…	…	…	…	…	
995	4.0	12.0	2.0	17.0	1.0	4.0	2.0	4.0	1.0	31.0	…	0.0	0.0	1.0	
996	1.0	30.0	2.0	39.0	1.0	3.0	1.0	4.0	2.0	40.0	…	0.0	1.0	1.0	
997	4.0	12.0	2.0	8.0	1.0	5.0	3.0	4.0	3.0	38.0	…	0.0	0.0	1.0	
998	1.0	45.0	2.0	18.0	1.0	3.0	3.0	4.0	4.0	23.0	…	0.0	0.0	1.0	
999	2.0	45.0	4.0	46.0	2.0	1.0	3.0	4.0	3.0	27.0	…	0.0	1.0	1.0	

	A19	A20	A21	A22	A23	A24	label
0	0.0	0.0	1.0	0.0	0.0	1.0	1.0
1	0.0	0.0	1.0	0.0	0.0	1.0	0.0
2	0.0	0.0	1.0	0.0	1.0	0.0	1.0
3	0.0	0.0	0.0	0.0	0.0	1.0	1.0
4	0.0	0.0	0.0	0.0	0.0	1.0	0.0
..	…	…	…	…	…	…	…
995	0.0	0.0	1.0	0.0	1.0	0.0	1.0
996	0.0	0.0	1.0	0.0	0.0	0.0	1.0
997	0.0	0.0	1.0	0.0	0.0	1.0	1.0
998	0.0	0.0	0.0	0.0	0.0	1.0	0.0
999	0.0	0.0	1.0	0.0	0.0	1.0	1.0

[1000 rows x 25 columns]

[5]:
```
data_frame.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 25 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   A1      1000 non-null   float64
 1   A2      1000 non-null   float64
```

```
 2   A3      1000 non-null   float64
 3   A4      1000 non-null   float64
 4   A5      1000 non-null   float64
 5   A6      1000 non-null   float64
 6   A7      1000 non-null   float64
 7   A8      1000 non-null   float64
 8   A9      1000 non-null   float64
 9   A10     1000 non-null   float64
 10  A11     1000 non-null   float64
 11  A12     1000 non-null   float64
 12  A13     1000 non-null   float64
 13  A14     1000 non-null   float64
 14  A15     1000 non-null   float64
 15  A16     1000 non-null   float64
 16  A17     1000 non-null   float64
 17  A18     1000 non-null   float64
 18  A19     1000 non-null   float64
 19  A20     1000 non-null   float64
 20  A21     1000 non-null   float64
 21  A22     1000 non-null   float64
 22  A23     1000 non-null   float64
 23  A24     1000 non-null   float64
 24  label   1000 non-null   float64
dtypes: float64(25)
memory usage: 195.4 KB
```

[6]:
```
data_frame.describe()
```

[6]:

	A1	A2	A3	A4	A5	\
count	1000.000000	1000.000000	1000.00000	1000.000000	1000.000000	
mean	2.577000	20.903000	2.54500	32.711000	2.105000	
std	1.257638	12.058814	1.08312	28.252605	1.580023	
min	1.000000	4.000000	0.00000	2.000000	1.000000	
25%	1.000000	12.000000	2.00000	14.000000	1.000000	
50%	2.000000	18.000000	2.00000	23.000000	1.000000	
75%	4.000000	24.000000	4.00000	40.000000	3.000000	
max	4.000000	72.000000	4.00000	184.000000	5.000000	

	A6	A7	A8	A9	A10	…	\
count	1000.000000	1000.00000	1000.000000	1000.000000	1000.000000	…	
mean	3.384000	2.68200	2.845000	2.358000	35.546000	…	
std	1.208306	0.70808	1.103718	1.050209	11.375469	…	
min	1.000000	1.00000	1.000000	1.000000	19.000000	…	
25%	3.000000	2.00000	2.000000	1.000000	27.000000	…	
50%	3.000000	3.00000	3.000000	2.000000	33.000000	…	
75%	5.000000	3.00000	4.000000	3.000000	42.000000	…	
max	5.000000	4.00000	4.000000	4.000000	75.000000	…	

```
                A16          A17          A18          A19          A20  \
count  1000.000000  1000.000000  1000.000000  1000.000000  1000.000000
mean      0.234000     0.103000     0.907000     0.041000     0.179000
std       0.423584     0.304111     0.290578     0.198389     0.383544
min       0.000000     0.000000     0.000000     0.000000     0.000000
25%       0.000000     0.000000     1.000000     0.000000     0.000000
50%       0.000000     0.000000     1.000000     0.000000     0.000000
75%       0.000000     0.000000     1.000000     0.000000     0.000000
max       1.000000     1.000000     1.000000     1.000000     1.000000

                A21          A22        A23          A24        label
count  1000.000000  1000.000000  1000.0000  1000.000000  1000.000000
mean      0.713000     0.022000     0.2000     0.630000     0.700000
std       0.452588     0.146757     0.4002     0.483046     0.458487
min       0.000000     0.000000     0.0000     0.000000     0.000000
25%       0.000000     0.000000     0.0000     0.000000     0.000000
50%       1.000000     0.000000     0.0000     1.000000     1.000000
75%       1.000000     0.000000     0.0000     1.000000     1.000000
max       1.000000     1.000000     1.0000     1.000000     1.000000

[8 rows x 25 columns]
```

4 *Data visualization*

[7]:
```
sns.pairplot(data_frame,
             hue='label',
             vars=['A'+str(i) for i in range(1, 10)])
```

[7]:
```
<seaborn.axisgrid.PairGrid at 0x79d6bec2b5b0>
```

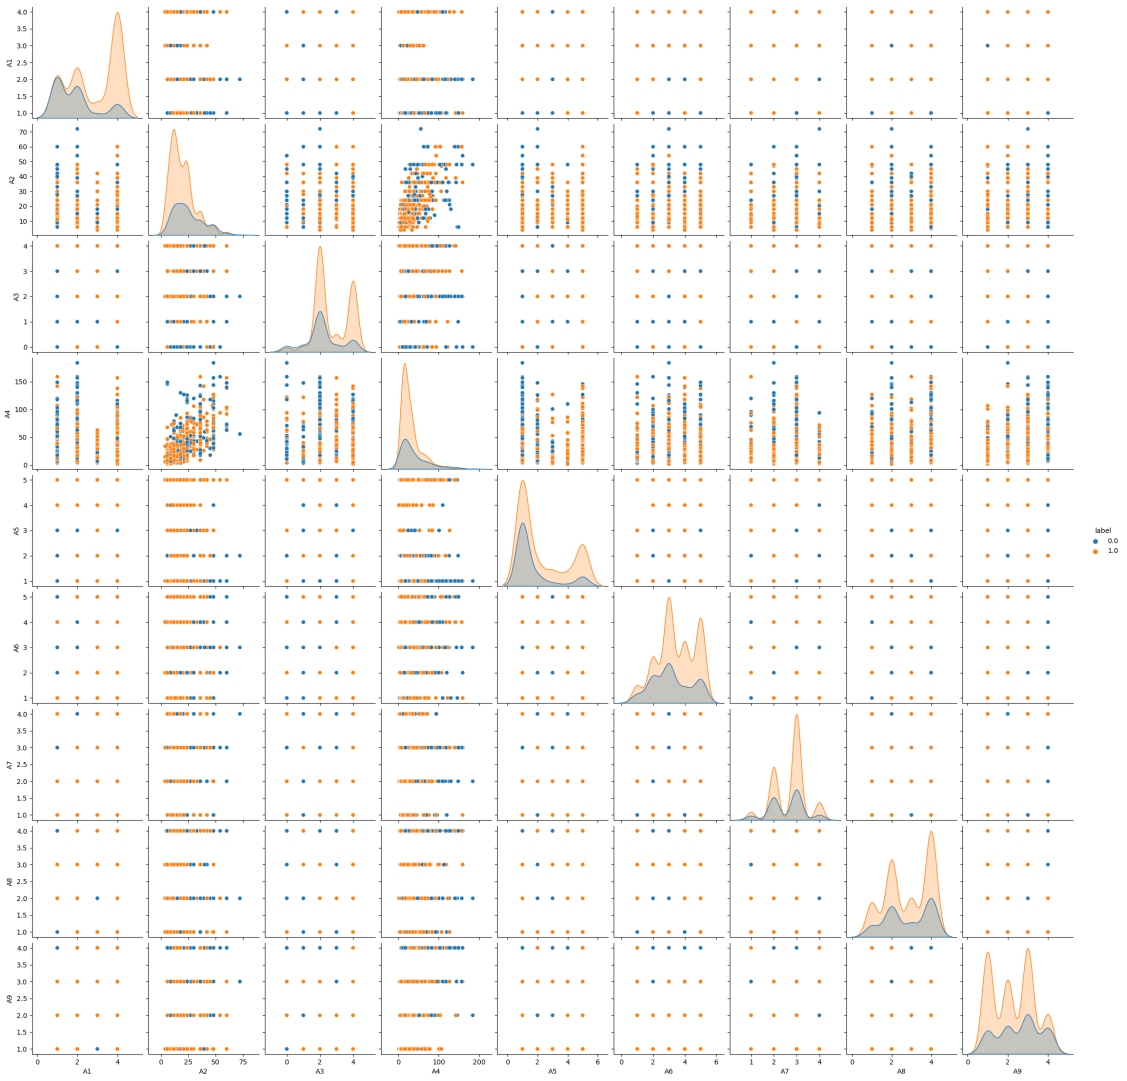

[8]:
```
sns.countplot(data_frame['label'])
```

[8]: <Axes: ylabel='count'>

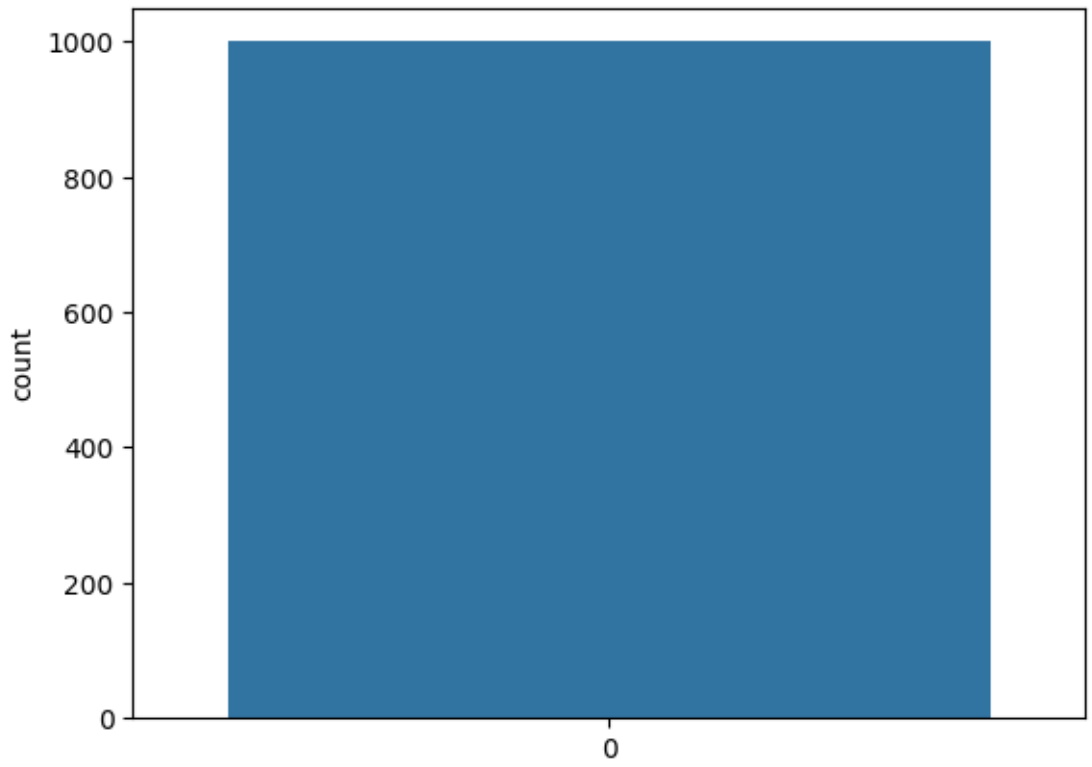

[9]:
```
plt.figure(figsize=(16,9))
sns.heatmap(data_frame)
```

[9]: <Axes: >

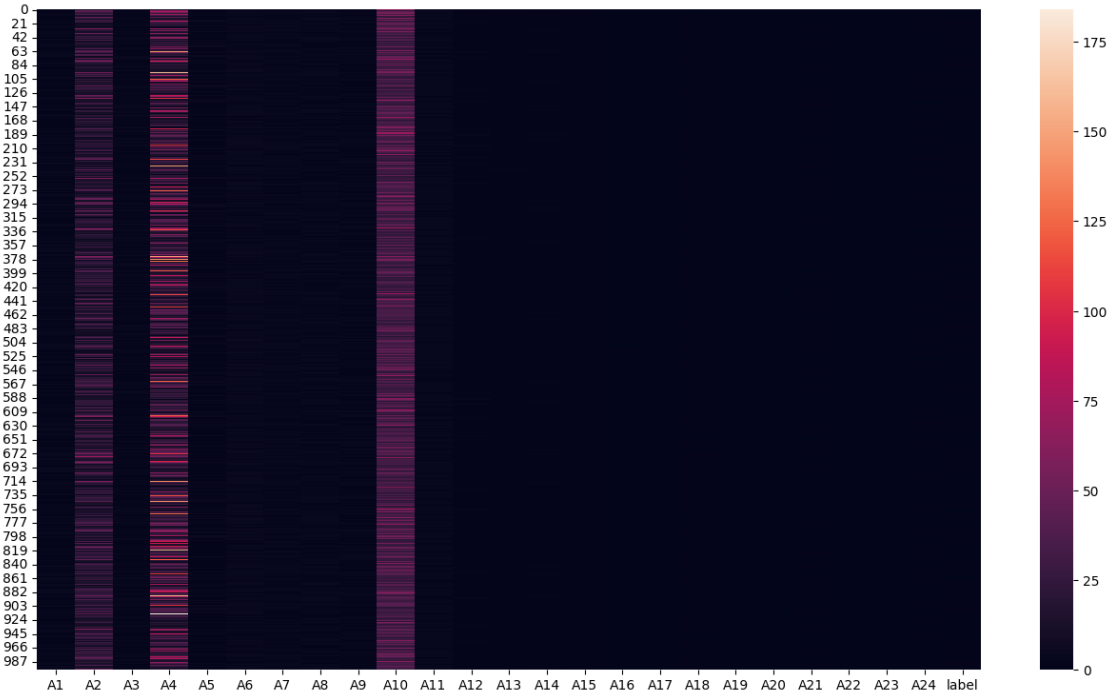

[10]:
```
plt.figure(figsize=(20,20))
sns.heatmap(data_frame.corr(), annot=True, cmap='coolwarm', linewidths=2)
```

[10]: <Axes: >

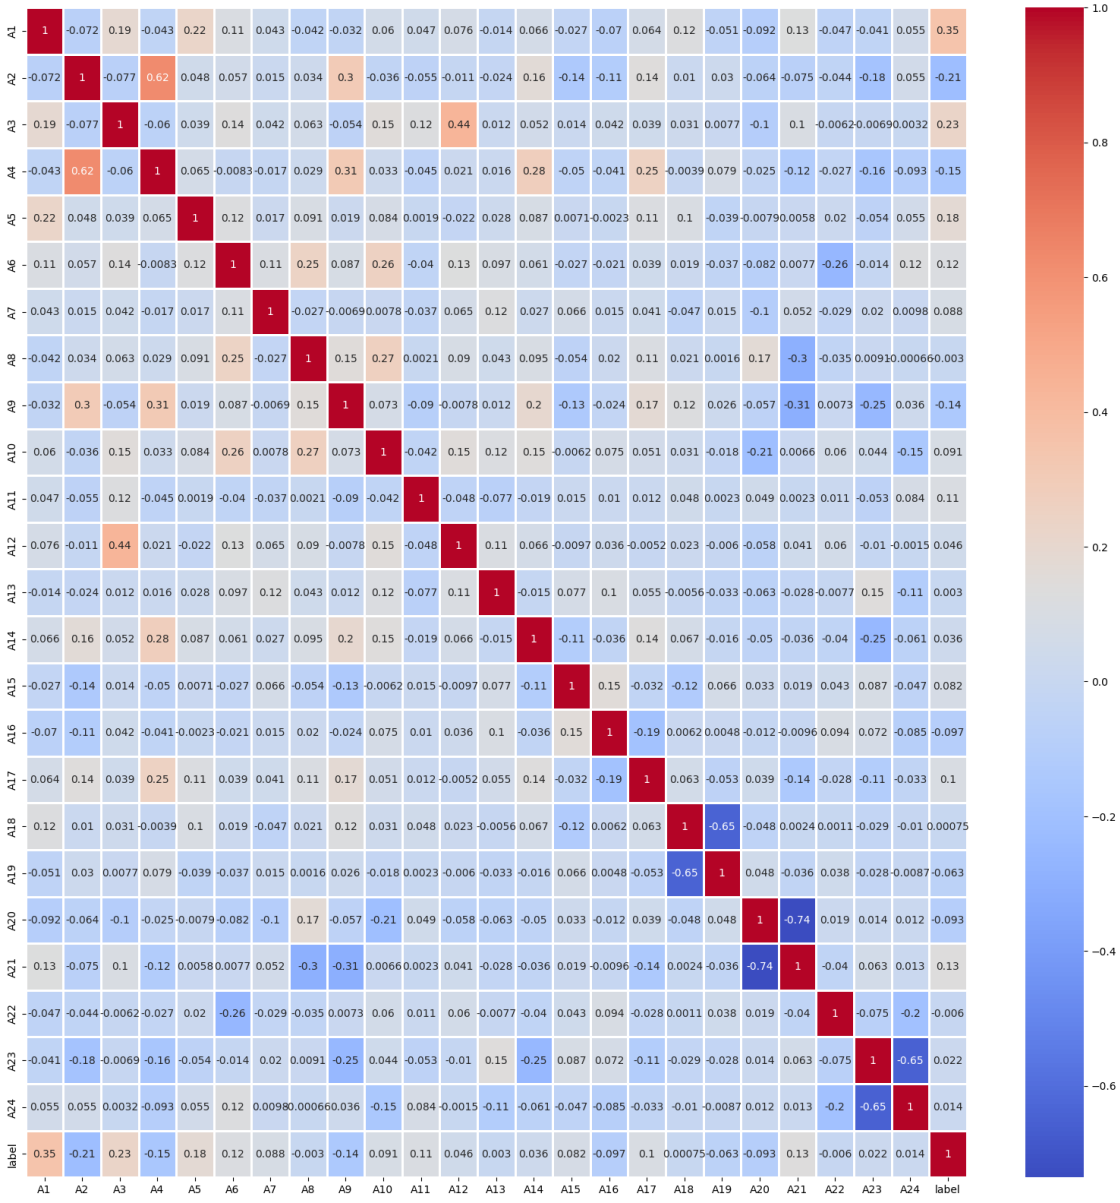

5 *Data preprocessing*

Normalization

[11]:
```
X = data_frame.drop(['label'], axis=1)
# X = (X-X.mean())/X.var()
X = (X-X.min())/(X.max()-X.min())
X
```

[11]:
```
           A1        A2    A3        A4    A5    A6        A7        A8  \
0    0.000000  0.029412  1.00  0.054945  1.00  1.00  0.666667  1.000000
1    0.333333  0.647059  0.50  0.318681  0.00  0.50  0.333333  0.333333
2    1.000000  0.117647  1.00  0.104396  0.00  0.75  0.666667  0.666667
3    0.000000  0.558824  0.50  0.423077  0.00  0.75  0.666667  1.000000
4    0.000000  0.294118  0.75  0.258242  0.00  0.50  0.666667  1.000000
..        …       …   …       …   …   …       …       …
995  1.000000  0.117647  0.50  0.082418  0.00  0.75  0.333333  1.000000
996  0.000000  0.382353  0.50  0.203297  0.00  0.50  0.000000  1.000000
997  1.000000  0.117647  0.50  0.032967  0.00  1.00  0.666667  1.000000
998  0.000000  0.602941  0.50  0.087912  0.00  0.50  0.666667  1.000000
999  0.333333  0.602941  1.00  0.241758  0.25  0.00  0.666667  1.000000

           A9       A10  …  A15  A16  A17  A18  A19  A20  A21  A22  A23  A24
0    0.000000  0.857143  …  0.0  0.0  0.0  1.0  0.0  0.0  1.0  0.0  0.0  1.0
1    0.000000  0.053571  …  0.0  0.0  0.0  1.0  0.0  0.0  1.0  0.0  0.0  1.0
2    0.000000  0.535714  …  0.0  0.0  0.0  1.0  0.0  0.0  1.0  0.0  1.0  0.0
3    0.333333  0.464286  …  0.0  0.0  0.0  0.0  0.0  0.0  0.0  0.0  0.0  1.0
4    1.000000  0.607143  …  0.0  1.0  0.0  1.0  0.0  0.0  0.0  0.0  0.0  1.0
..        …       …   …   …   …   …   …   …   …   …   …   …   …
995  0.000000  0.214286  …  0.0  0.0  0.0  1.0  0.0  0.0  1.0  0.0  1.0  0.0
996  0.333333  0.375000  …  0.0  0.0  1.0  1.0  0.0  0.0  1.0  0.0  0.0  0.0
997  0.666667  0.339286  …  0.0  0.0  0.0  1.0  0.0  0.0  1.0  0.0  0.0  1.0
998  1.000000  0.071429  …  0.0  0.0  0.0  1.0  0.0  0.0  0.0  0.0  0.0  1.0
999  0.666667  0.142857  …  0.0  0.0  1.0  1.0  0.0  0.0  1.0  0.0  0.0  1.0

[1000 rows x 24 columns]
```

[12]:
```
X.describe()
```

[12]:
```
                A1           A2          A3           A4           A5  \
count  1000.000000  1000.000000  1000.00000  1000.000000  1000.000000
mean      0.525667     0.248574     0.63625     0.168742     0.276250
std       0.419213     0.177336     0.27078     0.155234     0.395006
min       0.000000     0.000000     0.00000     0.000000     0.000000
25%       0.000000     0.117647     0.50000     0.065934     0.000000
50%       0.333333     0.205882     0.50000     0.115385     0.000000
75%       1.000000     0.294118     1.00000     0.208791     0.500000
max       1.000000     1.000000     1.00000     1.000000     1.000000

                A6           A7           A8           A9           A10  …  \
count  1000.000000  1000.000000  1000.000000  1000.000000  1000.000000  …
mean      0.596000     0.560667     0.615000     0.452667     0.295464  …
std       0.302077     0.236027     0.367906     0.350070     0.203133  …
min       0.000000     0.000000     0.000000     0.000000     0.000000  …
25%       0.500000     0.333333     0.333333     0.000000     0.142857  …
50%       0.500000     0.666667     0.666667     0.333333     0.250000  …
```

```
75%       1.000000     0.666667     1.000000     0.666667     0.410714  …
max       1.000000     1.000000     1.000000     1.000000     1.000000  …

               A15          A16          A17          A18          A19  \
count  1000.000000  1000.000000  1000.000000  1000.000000  1000.000000
mean      0.037000     0.234000     0.103000     0.907000     0.041000
std       0.188856     0.423584     0.304111     0.290578     0.198389
min       0.000000     0.000000     0.000000     0.000000     0.000000
25%       0.000000     0.000000     0.000000     1.000000     0.000000
50%       0.000000     0.000000     0.000000     1.000000     0.000000
75%       0.000000     0.000000     0.000000     1.000000     0.000000
max       1.000000     1.000000     1.000000     1.000000     1.000000

               A20          A21          A22        A23          A24
count  1000.000000  1000.000000  1000.000000  1000.0000  1000.000000
mean      0.179000     0.713000     0.022000     0.2000     0.630000
std       0.383544     0.452588     0.146757     0.4002     0.483046
min       0.000000     0.000000     0.000000     0.0000     0.000000
25%       0.000000     0.000000     0.000000     0.0000     0.000000
50%       0.000000     1.000000     0.000000     0.0000     1.000000
75%       0.000000     1.000000     0.000000     0.0000     1.000000
max       1.000000     1.000000     1.000000     1.0000     1.000000

[8 rows x 24 columns]
```

[13]:
```
plt.figure(figsize=(16,9))
sns.heatmap(X)
```

[13]:
```
<Axes: >
```

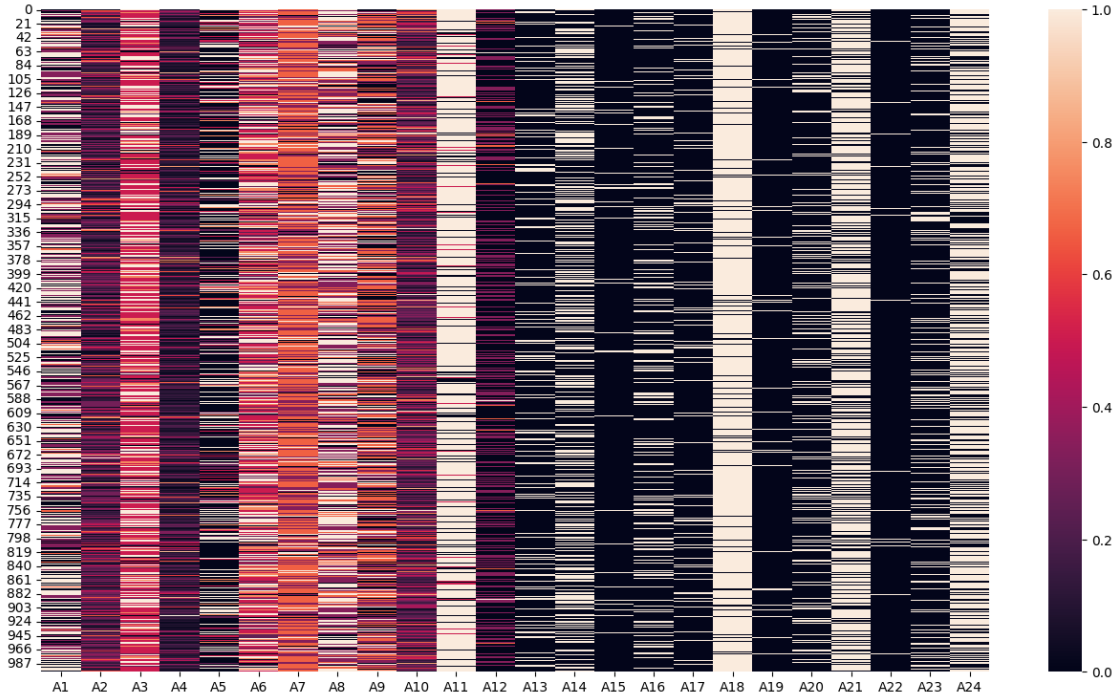

[14]:
```
y = data_frame['label']
y
```

[14]:
```
0      1.0
1      0.0
2      1.0
3      1.0
4      0.0
      ...
995    1.0
996    1.0
997    1.0
998    0.0
999    1.0
Name: label, Length: 1000, dtype: float64
```

5.1 Chia dữ liệu làm 2 phần training và testing

- Training chiếm 80 % dữ liệu
- Testing chiếm 20 % dữ liệu

[15]:
```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,␣
 ↪random_state=seed)
```

```
print("Dữ liệu training = ", X_train.shape, y_train.shape)
print("Dữ liệu testing = ", X_test.shape, y_test.shape)
```

```
Dữ liệu training =  (800, 24) (800,)
Dữ liệu testing =  (200, 24) (200,)
```

[16]:
```
from sklearn.metrics import precision_score, recall_score, accuracy_score
from sklearn.neighbors import KNeighborsClassifier
import matplotlib.pyplot as plt

%matplotlib inline
```

6 *K - Nearest Neightbor Classifier*

6.1 Bài toán phân loại sử dụng KNN

Mục tiêu:

- Xây dựng được mô hình KNN sử dụng thư viện sklearn.
- Ứng dụng, hiểu cách áp dụng mô hình KNN vào giải quyết bài toán thực tế (vd: phân loại)
- Sử dụng độ đo Accuracy, Precision, Recall để làm độ đo đánh giá chất lượng mô hình.

Vấn đề: - Có một tập các dữ liệu không có nhãn, làm sao để biết dữ liệu này là thuộc về nhãn nào. - => Xây dựng mô hình học máy có thể phân loại.

Dữ liệu: - Dữ liệu Bank Personal Loan Modelling - Xem thêm: https://www.kaggle.com/teertha/personal-loan-modeling

Bài toán: - Input: 1 mẫu dữ liệu $X = [x_1, x_2, ...x_n]$ - Output: nhãn y là 0 hoặc 1

[17]:
```
from sklearn.neighbors import KNeighborsClassifier
import matplotlib.pyplot as plt
%matplotlib inline
```

6.2 Mô hình KNN

Sử dụng thư viện sklearn để xây dựng mô hình - `KNeighborsClassifier(n_neighbors = 10, metric = 'minkowski', p = 2)` - Số láng giềng: n_neighbors = 5 - Độ đo khoảng cách: Euclide p = 2

[18]:
```
knn_classifier = KNeighborsClassifier(n_neighbors = 10, metric = 'minkowski', p␣
↪= 2, weights = 'distance')
knn_classifier.fit(X_train, y_train)
```

[18]:
```
KNeighborsClassifier(n_neighbors=10, weights='distance')
```

6.3 Testing KNN model

6.4 Đánh giá theo các độ đo

[19]:
```
def cost(y_true, y_pred):
    true_pos = ((y_true==y_pred)&(y_true==1.0))*0.0
    true_ne = ((y_true==y_pred)&(y_true==0.0))*0.0
    false_pos = ((y_true!=y_pred)&(y_true==1.0))*1.0
    false_ne = ((y_true!=y_pred)&(y_true==0.0))*5.0
    return sum(true_pos + true_ne + false_pos + false_ne)/len(y_true)
```

[20]:
```
from sklearn.metrics import precision_score, recall_score, accuracy_score

print("Testing...\n")
y_pred_knn = knn_classifier.predict(X_test)
print('Accuracy: ', accuracy_score(y_test, y_pred_knn))
print('Cost: ', cost(y_test, y_pred_knn))
# print('Precision: ', precision_score(y_test, y_pred_knn))
# print('Recall: ', recall_score(y_test, y_pred_knn))
```

```
Testing…

Accuracy:  0.76
Cost:  0.86
```

6.5 Lựa chọn mô hình

6.5.1 Lựa chọn số lượng láng giềng

- Thay đổi số lượng láng riềng tìm giá trị cho kết quả phân loại tốt nhất

6.5.2 Lựa chọn thuộc tính

- Các thuộc tính: A1-24
- Thử loại bỏ từng thuộc tính ra khỏi dữ liệu xem chúng ảnh hưởng như thế nào tới kết quả phân loại.
- Các thuộc tính nào nên được sử dụng để cho kết quả phân loại tốt nhất ?

6.5.3 Lựa chọn hàm tính khoảng cách

- Hàm tính khoảng cách: minkowski, manhattan, euclidean, chebyshev
- Hàm tính khoảng cách nào là tốt nhất cho bài toán này ?

6.5.4 Đánh giá việc lựa chọn số lượng láng giềng

[21]:
```
X = data_frame.drop(['label'], axis=1)
X = (X-X.min())/(X.max()-X.min())
y = data_frame['label']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,␣
 ↪random_state=seed)
```

[22]:
```
# Định nghĩa các giá trị số lượng làng giềng xem xét
n_neighbors = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 15, 18, 20, 22, 25, 30]
models = []
for k in n_neighbors:
    knn_classifier = KNeighborsClassifier(n_neighbors = k, metric =␣
 ↪'minkowski', p = 2, weights = 'distance')
    knn_classifier.fit(X_train, y_train)
    models.append(knn_classifier)
```

[23]:
```
# Visualize sự tác động của việc lựa chọn láng giếng lên hiệu năng mô hình trên␣
 ↪độ đo Accuracy
acc, pre, re = [], [], []
c = []
for model in models:
    y_pred = model.predict(X_test)
    acc.append(accuracy_score(y_test, y_pred))
    c.append(cost(y_test, y_pred))
#     pre.append(precision_score(y_test, y_pred))
#     re.append(recall_score(y_test, y_pred))

# Visualize
fig, axs = plt.subplots(1, 2, figsize = (20, 5))

axs[0].plot(n_neighbors, acc, marker= "v")
axs[0].set_xlabel("n_neighbors")
axs[0].set_ylabel("Accuracy")
axs[0].set_title("Ảnh hưởng của số lượng láng giềng")

axs[1].plot(n_neighbors, c, marker= "v")
axs[1].set_xlabel("n_neighbors")
axs[1].set_ylabel("Cost")
axs[1].set_title("Ảnh hưởng của số lượng láng giềng")

# axs[1].plot(n_neighbors, pre, marker= "v")
# axs[1].set_xlabel("n_neighbors")
# axs[1].set_ylabel("Precision")
# axs[1].set_title("Ảnh hưởng của số lượng láng giềng")

# axs[2].plot(n_neighbors, re, marker= "v")
# axs[2].set_xlabel("n_neighbors")
# axs[2].set_ylabel("Recall")
# axs[2].set_title("Ảnh hưởng của số lượng láng giềng")

plt.show()
```

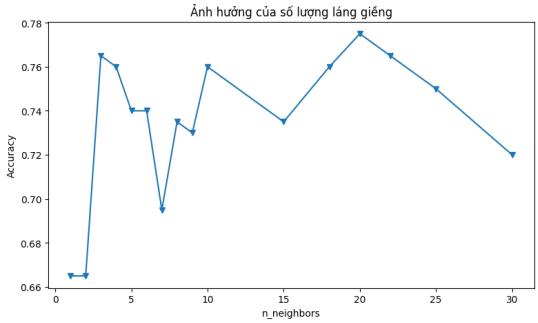

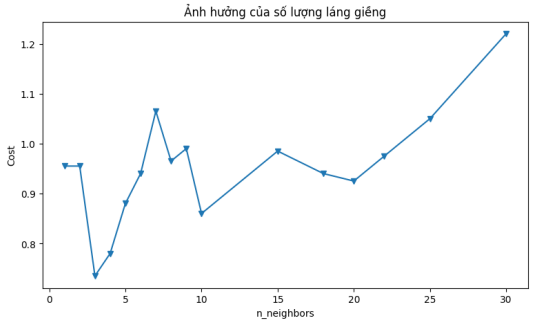

6.5.5 Đánh giá việc lựa chọn hàm khoảng cách

[24]:
```
k = 3
models = []

ps = [1,2,3,4,5,6,7,8,9,10,50, 'inf']
for p in ps:
    if p == 'inf':
        metric = 'chebyshev'
        p = 2
    else:
        metric = 'minkowski'
    knn_classifier = KNeighborsClassifier(n_neighbors = k, metric = metric, p =␣
 ↪p, weights = 'distance')
    knn_classifier.fit(X_train, y_train)
    models.append(knn_classifier)


acc, pre, re = [], [], []
c = []
for model in models:
    y_pred = model.predict(X_test)
    acc.append(accuracy_score(y_test, y_pred))
    c.append(cost(y_test, y_pred))
#     pre.append(precision_score(y_test, y_pred))
#     re.append(recall_score(y_test, y_pred))

# Visualize
fig, axs = plt.subplots(1, 2, figsize = (20, 5))

axs[0].plot(ps, acc, marker= "v")
axs[0].set_xlabel("p")
axs[0].set_ylabel("Accuracy")
axs[0].set_title("Ảnh hưởng của hàm tính khoảng cách")
```

```
axs[1].plot(ps, c, marker= "v")
axs[1].set_xlabel("p")
axs[1].set_ylabel("Cost")
axs[1].set_title("Ảnh hưởng của hàm tính khoảng cách")

# axs[1].plot(ps, pre, marker= "v")
# axs[1].set_xlabel("p")
# axs[1].set_ylabel("Precision")
# axs[1].set_title("Ảnh hưởng của hàm tính khoảng cách")

# axs[2].plot(ps, re, marker= "v")
# axs[2].set_xlabel("p")
# axs[2].set_ylabel("Recall")
# axs[2].set_title("Ảnh hưởng của hàm tính khoảng cách")

plt.show()
```

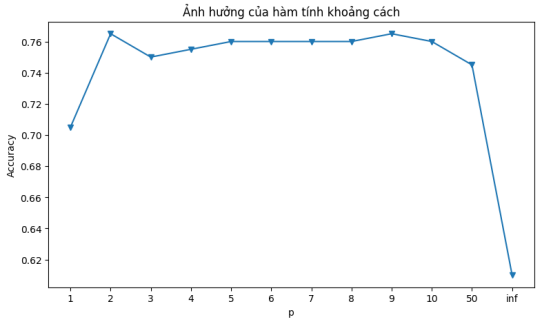

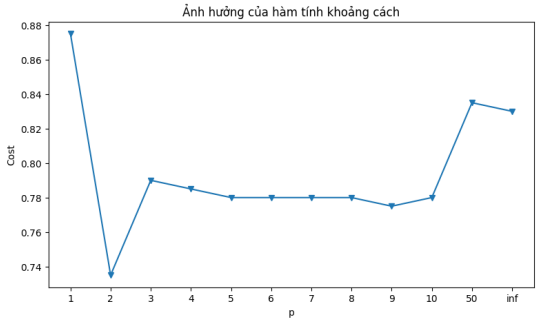

6.5.6 Đánh giá việc lựa chọn thuộc tính

[25]:
```
models = []
acc, pre, re = [], [], []
c = []
keys = ['None'] + ['A'+str(i) for i in range(1, 25)]
for key in keys:
    if key == 'None':
        X = data_frame.drop(['label'], axis=1)
    else:
        X = data_frame.drop(['label', key], axis=1)
    X = (X-X.min())/(X.max()-X.min())
    y = data_frame['label']
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,␣
 ↪random_state=seed)
```

```
    knn_classifier = KNeighborsClassifier(n_neighbors = 3, metric =␣
 ↪'minkowski', p = 2, weights = 'distance')
    knn_classifier.fit(X_train, y_train)
    y_pred = knn_classifier.predict(X_test)
    acc.append(accuracy_score(y_test, y_pred))
    c.append(cost(y_test, y_pred))
#     pre.append(precision_score(y_test, y_pred))
#     re.append(recall_score(y_test, y_pred))


# Visualize
fig, axs = plt.subplots(1, 2, figsize = (20, 5))

axs[0].plot(keys, acc, marker= "v")
axs[0].set_xlabel("keys")
axs[0].set_ylabel("Accuracy")
axs[0].set_title("Ảnh hưởng của từng thuộc tính")
axs[0].plot(keys, [acc[0] for _ in range(len(acc))], marker = '', label =␣
 ↪'Baseline')
axs[0].set_xticklabels(keys, rotation=45)

axs[1].plot(keys, c, marker= "v")
axs[1].set_xlabel("keys")
axs[1].set_ylabel("Cost")
axs[1].set_title("Ảnh hưởng của từng thuộc tính")
axs[1].plot(keys, [c[0] for _ in range(len(acc))], marker = '', label =␣
 ↪'Baseline')
axs[1].set_xticklabels(keys, rotation=45)

# axs[1].plot(keys, re, marker= "v")
# axs[1].set_xlabel("keys")
# axs[1].set_ylabel("Recall")
# # axs[1].set_title("Ảnh hưởng của hàm tính khoảng cách")
# axs[1].plot(keys, [re[0] for _ in range(len(re))], marker = '', label =␣
 ↪'Baseline')
# axs[1].set_xticklabels(keys, rotation=45)

# axs[2].plot(keys, pre, marker= "v")
# axs[2].set_xlabel("keys")
# axs[2].set_ylabel("Precision")
# # axs[2].set_title("Ảnh hưởng của hàm tính khoảng cách")
# axs[2].plot(keys, [pre[0] for _ in range(len(pre))], marker = '', label =␣
 ↪'Baseline')
# axs[2].set_xticklabels(keys, rotation=45)

plt.show()
```

```
plt.legend()
c = np.array(c)
print(np.where(c<c[0]))

acc = np.array(acc)
print(np.where(acc>acc[0]))
```

```
<ipython-input-25-fff11a33dcb5>:31: UserWarning: FixedFormatter should only be
used together with FixedLocator
  axs[0].set_xticklabels(keys, rotation=45)
<ipython-input-25-fff11a33dcb5>:38: UserWarning: FixedFormatter should only be
used together with FixedLocator
  axs[1].set_xticklabels(keys, rotation=45)
```

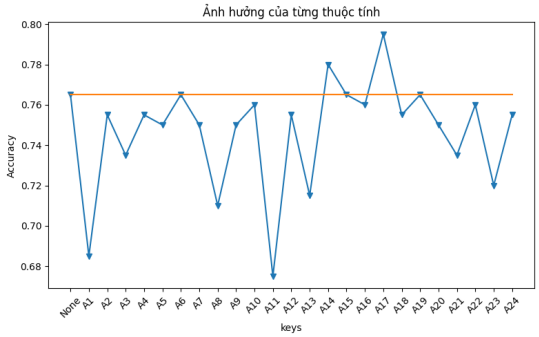

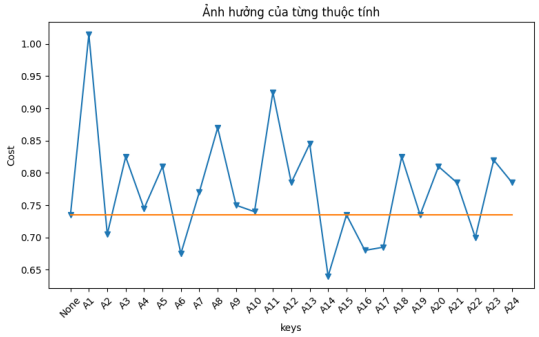


```
WARNING:matplotlib.legend:No artists with labels found to put in legend.  Note
that artists whose label start with an underscore are ignored when legend() is
called with no argument.
```

```
(array([ 2,  6, 14, 16, 17, 22]),)
(array([14, 17]),)
```

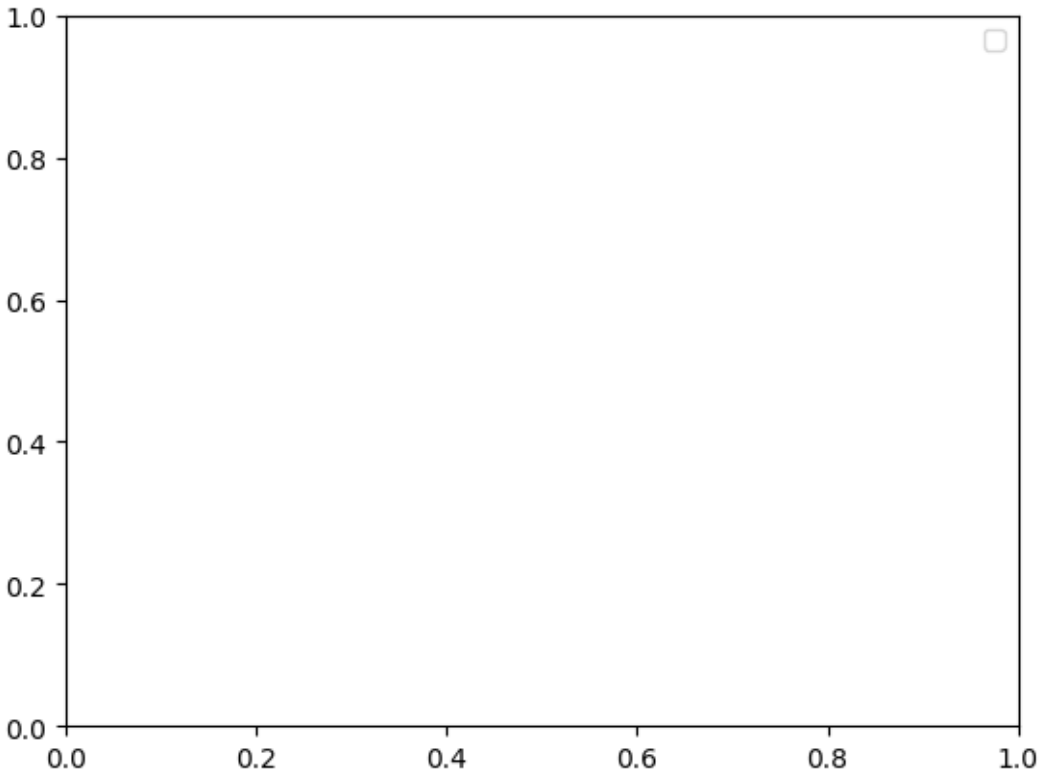

[26]:
```
# loại bỏ tất cả các thuộc tính làm giảm cost
X = data_frame.drop(['A'+str(i) for i in list(np.where(c<c[0])[0])] +␣
 ↪['label'], axis=1)
X = (X-X.min())/(X.max()-X.min())
y = data_frame['label']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,␣
 ↪random_state=seed)

knn_classifier = KNeighborsClassifier(n_neighbors = 3, metric = 'minkowski', p␣
 ↪= 2, weights = 'distance')
knn_classifier.fit(X_train, y_train)

print("Testing...\n")
y_pred_knn = knn_classifier.predict(X_test)
print('Accuracy: ', accuracy_score(y_test, y_pred_knn))
print('Cost: ', cost(y_test, y_pred_knn))
# print('Precision: ', precision_score(y_test, y_pred_knn))
# print('Recall: ', recall_score(y_test, y_pred_knn))
```

```
Testing...

Accuracy:  0.725
```

```
Cost:  0.915
```

[27]:
```
# loại bỏ thuộc tính làm giảm cost nhiều nhất A14
X = data_frame.drop(['A14', 'label'], axis=1)
X = (X-X.min())/(X.max()-X.min())
y = data_frame['label']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,␣
 ↪random_state=seed)

knn_classifier = KNeighborsClassifier(n_neighbors = 3, metric = 'minkowski', p␣
 ↪= 2, weights = 'distance')
knn_classifier.fit(X_train, y_train)

print("Testing...\n")
y_pred_knn = knn_classifier.predict(X_test)
print('Accuracy: ', accuracy_score(y_test, y_pred_knn))
print('Cost: ', cost(y_test, y_pred_knn))
# print('Precision: ', precision_score(y_test, y_pred_knn))
# print('Recall: ', recall_score(y_test, y_pred_knn))
```

```
Testing...

Accuracy:  0.78
Cost:  0.64
```

7 Others

[28]:
```
X = data_frame.drop(['label'], axis=1)
X = (X-X.min())/(X.max()-X.min())
y = data_frame['label']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,␣
 ↪random_state=seed)
```

Navie Bayes Classifier

[29]:
```
from sklearn.naive_bayes import GaussianNB
nb_classifier = GaussianNB()
nb_classifier.fit(X_train, y_train)
y_pred_nb = nb_classifier.predict(X_test)
print('Accracy: ', accuracy_score(y_test, y_pred_nb))
print('Cost: ', cost(y_test, y_pred_nb))
# print('Precision: ', precision_score(y_test, y_pred_nb))
# print('Recall: ', recall_score(y_test, y_pred_nb))
```

```
Accracy:  0.71
Cost:  0.73
```

Support Vector Classifier

[30]:
```
from sklearn import svm
svm_classifier = svm.SVC(kernel='linear')
svm_classifier.fit(X_train, y_train)
y_pred_svm = svm_classifier.predict(X_test)
print('Accuracy: ', accuracy_score(y_test, y_pred_svm))
print('Cost: ', cost(y_test, y_pred_svm))
# print('Precision: ', precision_score(y_test, y_pred_sum))
# print('Recall: ', recall_score(y_test, y_pred_sum))
```

```
Accuracy:  0.755
Cost:  0.885
```

Logistic Regression

[31]:
```
from sklearn.linear_model import LogisticRegression
lr_classifier = LogisticRegression(random_state=seed)
lr_classifier.fit(X_train, y_train)
y_pred_lr = lr_classifier.predict(X_test)
print('Accuracy: ', accuracy_score(y_test, y_pred_lr))
print('Cost: ', cost(y_test, y_pred_lr))
# print('Precision: ', precision_score(y_test, y_pred_lr))
# print('Recall: ', recall_score(y_test, y_pred_lr))
```

```
Accuracy:  0.77
Cost:  0.87
```

Decision Tree Classifier

[32]:
```
from sklearn.tree import DecisionTreeClassifier
dt_classifier = DecisionTreeClassifier(criterion = 'entropy', random_state =␣
 ↪seed)
dt_classifier.fit(X_train, y_train)
y_pred_dt = dt_classifier.predict(X_test)
print('Accuracy: ', accuracy_score(y_test, y_pred_dt))
print('Cost: ', accuracy_score(y_test, y_pred_dt))
# print('Precision: ', precision_score(y_test, y_pred_dt))
# print('Recall: ', recall_score(y_test, y_pred_dt))
```

```
Accuracy:  0.715
Cost:  0.715
```

Random Forest Classifier

[33]:
```
from sklearn.ensemble import RandomForestClassifier
rf_classifier = RandomForestClassifier(n_estimators = 20, criterion =␣
 ↪'entropy', random_state = seed)
rf_classifier.fit(X_train, y_train)
y_pred_rf = rf_classifier.predict(X_test)
print('Accuracy: ', accuracy_score(y_test, y_pred_rf))
```

```
print('Cost: ', cost(y_test, y_pred_rf))
# print('Precision: ', precision_score(y_test, y_pred_rf))
# print('Recall: ', recall_score(y_test, y_pred_rf))
```

```
Accuracy:  0.79
Cost:  0.77
```